

SK하이닉스 GHeSS 프로젝트

GHeSS AI Agent 서비스 아키텍처 초안

컴포넌트 구성 · 처리 흐름 · 데이터 구조 · 인터페이스 · WBS 작업 패키지 매핑

문서 성격 **설계 초안(Draft)** — 확정 설계가 아니며, 착수 후 확인 결과에 따라 변경

작성 기준일 2026-08-03

선행 문서 『GHeSS AI Agent 요구사항 분석 및 실행 계획』

전제 관련 인프라·모델 대체로 가용 가정 — 인터페이스 우선 설계

용도 상세 설계·**WBS 작성의 기준 문서** — 모듈 경계가 작업 패키지 경계가 되도록 구성

목차

- 1. 설계 원칙과 제약 3
- 2. 논리 아키텍처 (계층·컴포넌트) 4
- 3. 질의 처리 흐름 7
- 4. Agent 구성과 도구 카탈로그 9
- 5. Data Pipeline 처리 흐름 12
- 6. 데이터 저장 구조 초안 18
- 7. 인터페이스 초안 20
- 8. 배포·운영 토폴로지 21
- 9. 아키텍처 결정 기록 (ADR 요약) 22
- 10. WBS 연계 — 모듈·작업 패키지 매핑 23

1. 설계 원칙과 제약

본 초안은 사내 표준 스택·인프라가 확정되지 않은 상태에서 작성되었습니다. 따라서 특정 프레임워크나 제품을 전제하지 않고 **컴포넌트의 책임과 인터페이스를 먼저 명시**하는 방식으로 설계합니다. 관련 인프라·모델은 **대체로 가용하다는 가정**하에 작성한 초안이며, 구현 기술은 착수 후 확인 결과에 따라 결정합니다.

원칙	내용과 근거
외부 의존 격리	LLM·임베딩은 GiaA에 의존하므로 추상화 계층(Model Gateway) 을 두어 상위 로직이 특정 모델·API 규격에 묶이지 않도록 합니다. 모델 교체·버전 전환이 설정 변경으로 처리되어야 합니다.
검색 우선, 작성 후행	문서 작성 지원은 검색·자산화 기반 위에서만 성립하므로 의존성 역순으로 구축합니다. 파이프라인 → 검색 → 요약 → 작성 순.
제어된 에이전틱	도구 라우팅은 필요하나 자율 루프는 제한합니다. 고정 도구 세트 + 반복 상한 으로 응답 시간·호출 비용·회귀 검증 가능성을 확보합니다.
근거 우선 응답	규정 도메인 특성상 답변은 항상 근거 문서에 연결되어야 하며, 근거가 없으면 "문서에 없음"으로 응답하는 것을 기본 동작으로 둡니다.
폐쇄망 전제	외부 인터넷 호출이 불가능할 수 있다고 가정하고, 모델·패키지·리소스를 사내에서 조달 가능한 구조로 설계합니다.
단일 진입점 UI	MVP는 G-HeSS 내 단독 페이지로 제공하되, 컴포넌트와 호스트 의존부를 분리해 이후 위젯 전환 시 재작성이 없도록 합니다.
재현 가능한 파이프라인	문서 정제·색인은 재실행 가능해야 합니다. 원본 → 산출물의 변환이 결정적이고 버전 추적이 가능해야 재색인·품질 개선이 반복됩니다.

2. 논리 아키텍처 (계층·컴포넌트)

계층 간 호출은 위에서 아래로만 이루어지며, 하위 계층이 상위를 직접 호출하지 않습니다(알림 등 역방향 전달은 이벤트/큐를 경유). 각 컴포넌트의 책임을 한 줄로 고정해 경계를 명확히 합니다.

2.1 계층 구성




그림 A. 계층 구성 레이어 뷰 — 상위→하위 단방향 호출, 공통 계층은 전 계층에 적용

계층	컴포넌트	책임
표현 (Presentation)	Chat UI	대화 화면, 스트리밍 표시, 처리 상태 피드백, 파일 업/다운로드. 호스트 의존부(인증 토큰·테마)를 어댑터로 분리
	History / Session View	세션 목록, 과거 대화 조회·키워드 검색
	Usage Dashboard	부서별·기간별 사용 현황 기본 지표 표시
API (BFF)	Chat API	질의 접수, 응답 스트리밍(SSE 등), 상태 이벤트 송출
	Session API	세션 생성·조회·만료, 메시지 이력 CRUD
	File API	업로드 검증(확장자·용량·검사), 다운로드 서명 URL 발급
	Admin API	모델 버전 전환, 재색인 트리거, 지표 조회

Agent Core	Orchestrator	의도 분류 → 도구 선택 → 실행 → 결과 종합. 반복 상한과 타임아웃 관리
	Tool Registry	고정 도구 세트 등록·스키마 관리(§ 4)
	Context Builder	생성 직전의 프롬프트 컨텍스트 조립 — 시스템 지시문 · 검색 근거 · 세션 맥락에 토큰 예산(아래 노트)을 배분하고, 재랭킹 상위 근거를 우선 배치. 짧은 청크는 부 모 청크로 맥락을 확장하고, 긴 대화는 최근 턴 원문 + 이전 턴 요약으로 압축. 각 근거에 출처 식별자를 태깅해 생성 단계의 인용 강제(§ 3 6단계)와 연결
	Grounding Verifier	생성 답변의 근거 일치 검증, 미달 시 재생성 또는 "문서에 없음" 전환
	Model Gateway	GiaA 호출 추상화 — 모델 매핑, 재시도·쿼터 제어, 토큰 사용량 기록
Retrieval	Query Normalizer	질의 정규화(대소문자·하이픈·전각/반각·공백), 문서번호 패턴 인식
	Hybrid Searcher	키워드(BM25) + 벡터 검색 병합 — 키워드 측은 기 구축된 Elasticsearch 활용 을 우선 검토(아래 노트). 메타 필터(Site·레벨·상태·권한)는 검색 시점에 적용(사 후 조인 없음)
	Reranker	병합 결과 재정렬 — 문서 레벨·최신 개정·유사도 가중
	Relation Resolver	인용·개정 계보·상하위 관계 조회(연관 문서, Rev. 비교의 기반)
Data Pipeline	Ingestor	원본 문서 수집, 변경 감지, 문서 유형 태그 부여(사전 프로파일 — § 5.2), 처리 큐 적재
	Parser	형식별 텍스트·구조 추출(Excel/PDF/구 Office)
	Asset Classifier	이미지 유형 판별(화면 캡처·표·도식·차트·스캔 텍스트·장식) → 유형별 처리 경로 결정(라우팅의 진입점) . 컨텍스트 우선 판별: 문서 맥락 신호(캡션·주변 텍스트) → 모호 시 VLM 저비용 호출(§ 5.2 판별 구성)
	Structure Extractor	유형별 판독 실행 — OCR·VLM 조합 호출, 표/도식의 구조화 산출물 생성(§ 5.2)
	Vision Gateway	OCR·VLM 모델 호출 추상화 — 모델 라우팅, 재시도, 신뢰도 수집, 비용 집계
	Chunker / Embedder	청킹 정책 적용, 임베딩 생성, 인덱스 적재
	Metadata Extractor	문서 메타·관계 추출(문서번호·Owner·Site·인용·개정 이력), 문서 요약 생성(doc_summary — § 5.1 노트)
Integration	Notification Adapter	CUBE 알림 전송(방식 확정 후 구현체 교체 가능하도록 인터페이스 고정)
	External I/F Adapter	전자결재·HR 연동 어댑터. 각 시스템 규격 변화를 이 계층에서 흡수
공통 (Cross-cutting)	인증·인가 (AuthN/AuthZ)	인증(AuthN): SSO 연동 사용자 확인 / 인가(AuthZ): 문서 접근 권한 판정(검색 결과 필터링 지점)
	Audit Logger	검색·요약·다운로드 행위 기록
	Observability	요청 추적, 지연·오류·토큰 사용량 지표

토큰 예산 — 한 번의 생성 호출에서 입력으로 쓸 수 있는 토큰 총량을 지시문 · 검색 근거 · 대화 이력의 항목별 한도로 미리 배분한 것입니다. 한도 초과 시의 삭감 규칙(순위 낮은 근거부터 제외, 이력은 요약 압축)이 함께 정의되어, 대화가 길어져도 근거 분량이 항상 확보됩니다. 컨텍스트 윈도우가 큰 모델에서도 이 방식을 유지합니다 — 비용·지연이 입력량에 비례하고, 무관 정보의 과다 투입은 인용 정확도를 떨어뜨리며, 배정 모델의 창 크기와 무관하게 동일 구조가 성립하기 때문입니다. 큰 창은 문서 전문 투입(지정 문서 요약)이나 이미지 중심 문서의 시퀀스 해석처럼 항목 한도를 키우는 방향으로 활용합니다.

기 구축 Elasticsearch 활용 — 기존 문서 텍스트가 이미 Elasticsearch에 색인되어 있는 것으로 확인되었습니다. 활용 방향은 세 가지입니다. ① **키워드 검색 축 재사용** — 하이브리드 검색의 키워드(BM25) 축을 신규 구축하지 않고 기존 클러스터에 두면 구축·운영 부담이 줄어듭니다. 다만 기존 인덱스는 문서 단위일 가능성이 높아, 검색 결과를 답변 근거(청크 단위)로 연결하려면 본 설계의 청킹 체계에 맞춘 **청크 단위 전용 인덱스를 같은 클러스터에 신설**하는 방식이 안전합니다. 두 축의 점수 체계 차이는 순위 기반 병합(RRF)을 사용하므로 문제가 되지 않습니다. ② **파싱 교차 검증** — 파이프라인이 추출한 텍스트와 기존 색인 텍스트를 대조해 파싱 누락·오류를 조기에 발견하는 검증 소스로 사용합니다. 문서 목록 대조로 수집 커버리지 확인에도 활용됩니다. ③ **조기 가동** — 벡터 색인 완료 전에도 기존 인덱스만으로 키워드 검색 기반의 초기 화면을 가동해 검색 UI·권한 연동을 먼저 검증할 수 있습니다. 확인 필

요 사항은 인덱스 단위(문서/문단), 한국어 분석기 적용 여부, 보유 필드(메타데이터 범위), 개정 시 갱신 방식, 신규 인덱스 생성 권한, 접근 방식(API·계정)이며 착수 초기에 확인합니다.

2.2 배치(Batch) 구성

상시 요청 처리와 분리되어 스케줄로 동작하는 작업입니다. 자원 경합을 피하기 위해 별도 워커로 운영합니다.

작업	주기·트리거	내용
신규 문서 상시 정제	등록 이벤트 또는 주기	신규·개정 문서 파싱 → 색인 반영
전체 재색인	수동·모델 변경 시	임베딩 모델 교체·청킹 정책 변경 시 전량 재처리
다량 문서 일괄 요약	요청 기반 배치	대상 집합에 대한 요약·검토 일괄 수행
세션 타임아웃 집계	시간 단위	만료 세션 정리 및 이용 통계 집계
평가 회귀 측정	빌드·주기	평가셋 기반 검색·생성 품질 측정, 지표 기록

3. 질의 처리 흐름

3.1 표준 질의응답 경로

단계	처리	내용 · 상태 표시
1	질의 접수	Chat API가 질의·세션ID 수신 → 세션 맥락 로드. 화면에 "질의 분석" 상태 표시
2	정규화·의도 분류	Query Normalizer가 질의 정규화, 문서번호 패턴 여부 판별 → Orchestrator가 의도 분류(문서 지정 조회 / 자연어 검색 / 요약 / 비교 / 작성)
3	도구 실행	의도에 따라 도구 호출(§ 4). 검색 계열은 Hybrid Searcher → Reranker → 권한 필터 순. "문서 검색" 상태 표시
4	충분성 판단	결과 부족 시 질의 재작성 1회 까지 허용 후 재검색. 그래도 부족하면 "관련 문서를 찾지 못함"으로 응답 전환
5	컨텍스트 구성	Context Builder가 상위 근거 청크 + 문서 메타 + 세션 맥락을 토큰 예산 내로 구성
6	답변 생성	Model Gateway 경유 생성, 토큰 스트리밍 시작. 출처 인용을 강제하는 응답 형식 사용
7	근거 검증	Grounding Verifier가 근거 일치 확인. 미달 시 재생성 1회 또는 "문서에 없음" 전환. "근거 검증" 상태 표시
8	응답 확정	출처 링크·재구성 자산(표·도식) 첨부, 세션 저장, 감사 로그 기록, 피드백 UI 노출

제어된 Agentic RAG — 검색 흐름 안의 판단 지점 5곳 — 위 흐름은 "질의 → 검색 → 생성"을 항상 같은 순서로 도는 고정 파이프라인이 아니라, 다음 지점에서 에이전트의 판단이 개입해 경로가 달라지는 Agentic RAG로 동작합니다. ① **검색 도구 선택**(3단계): 질의 성격에 따라 metadata_search·vector_search·keyword_search·relation_lookup의 조합과 순서를 에이전트가 결정 — 문서번호 조회와 자연어 질의가 다른 경로를 탐니다. ② **질의 재작성**(4단계): 결과 부족 시 질의를 재구성해 재검색. ③ **메타 필터 조합**: 질의 맥락에서 Site·레벨·상태 조건을 추출해 검색 필터로 조립. ④ **관계 추적형 다단 검색**: 찾은 문서의 인용·개정 계보를 relation_lookup으로 따라가 연관 문서까지 확장. ⑤ **검증 후 재시도**(7단계): 근거 미달 시 재생성 또는 "문서에 없음" 전환. 이 판단들은 모두 **고정 도구 카탈로그 (§ 4)**와 **반복 상한 안에서만** 동작합니다.

반복 상한 — 질의 재작성 1회, 재생성 1회로 고정합니다. 자율 반복을 허용하면 응답 시간과 호출량이 예측 불가능해지고, 동일 입력에 대한 결과가 흔들려 회귀 검증이 어려워집니다. 상한 완화는 오픈 후 사용 데이터를 근거로 검토합니다.




그림 B. 질의 처리 흐름 — 재작성·재생성 각 1회 상한, 미달 시 안전 응답 전환

3.2 상태 이벤트 (처리 상태 피드백)

단계 전환 시 UI로 상태 이벤트를 전송해 로딩·진행 표시를 단일 명세로 처리합니다. 생성 구간은 토큰 스트리밍 자체가 진행 표시가 되므로 별도 진행률을 사용하지 않습니다.

이벤트	발생 시점	UI 표현
stage.started	각 단계 진입	단계명 점등 (N단계 중 M단계)
token.delta	생성 스트리밍	텍스트 순차 출력, 비정량 인디케이터
progress.count	배치·파일 처리	정량 Progress Bar (처리 건수/전체)

result.final	응답 확정	출처·첨부 렌더링, 피드백 버튼 활성화
error.raised	예외	예외 메시지 표시, 재시도 안내

4. Agent 구성과 도구 카탈로그

4.1 도구 카탈로그

Orchestrator가 호출할 수 있는 도구를 고정 세트로 정의합니다. 도구 추가는 설계 변경으로 취급하며, 각 도구는 입력·출력 스키마를 명시해 회귀 테스트가 가능하도록 합니다.

도구	입력 → 출력	용도 · 대응 요구
metadata_search	필터(문서번호·Owner·부서·Site·레벨) → 문서 목록	구조화 조건 검색. 문서번호 체계 검색(행 21), Site 구분(행 20)
vector_search	질의문·top_k → 근거 청크 목록	자연어·유사어 의미 검색(행 15·16)
keyword_search	키워드·필터 → 청크 목록	정확 일치·약어 검색. 하이브리드 검색의 한 축
doc_fetch	문서번호 → 본문·메타·첨부 자산	지정 문서 조회·요약(행 30)의 선행
relation_lookup	문서번호·관계유형 → 연관 문서 목록	연관 문서 검색(행 25), 개정 계보·상하위 조회(행 24)
revision_diff	문서번호·Rev A/B → 변경점 목록	Rev. 전/후 비교(행 19)
summarize	문서·범위·형식 → 요약문	문서 요약(행 30), 개정 요약(행 51)
verify_grounding	답변·근거 → 문장별 근거 판정	Hallucination 방지(행 26)
draft_generate	문서 유형·입력 정보 → 초안 파일	표준 초안 작성(행 33·35)
checklist_validate	초안 파일 → 항목별 충족 여부	DCC Checklist 검증(행 36~38)

MVP 범위는 metadata_search · vector_search · keyword_search · doc_fetch · summarize · verify_grounding 6종이며, relation_lookup·revision_diff는 관계 메타데이터 확보가, draft_generate·checklist_validate는 초안 작성 기능 편입이 각각 전제입니다.

4.2 다중 에이전트 구성

챗봇 내부는 역할별 전문 에이전트가 분담하는 **다중 에이전트 구조**로 설계합니다. 사용자에게는 **하나의 대화 채널**로 보이며, 내부 분담은 노출되지 않습니다. 질의 성격이 이질적인 상황에서 하나의 프롬프트·루프에 모든 역할을 담으면 지시문이 비대해지고 한 영역의 튜닝이 다른 영역을 퇴행시키므로, 역할을 분리해 각 영역을 독립적으로 개선·측정할 수 있게 합니다. 다만 호출량·지연·비결정성이 함께 늘지 않도록 구조는 전체를 갖추되 실행은 단계적으로 확장합니다.

에이전트	담당 영역	보유 도구 · 특성
Router (진입점)	질의 의도 분류, 담당 에이전트 선택, 결과 통합·응답 형식 결정	도구 없음. 경량·저지연 모델 사용. 분류가 모호하면 기본값(문서 탐색)으로 위임
문서 탐색 Retrieval Agent	자연어·유사어 검색, 조건 검색, 연관 문서 추적, 결과 정렬	metadata_search · vector_search · keyword_search · relation_lookup. 검색 전략(질의 재작성·필터 조합)에 특화
문서 해석 Reading Agent	지정 문서 요약, 조항 설명, Rev. 변경점 비교	doc_fetch · summarize · revision_diff. 장문 컨텍스트 처리와 인용 정확성에 특화
검증 Verifier	생성 답변의 근거 일치 판정, 미달 시 재 생성·"문서에 없음" 전환 지시	verify_grounding. 독립 판정을 위해 생성 에이전트와 분리
문서 작성 Authoring Agent	표준 초안 생성, 대화형 정보 수집, Checklist 검증	draft_generate · checklist_validate · doc_fetch. 멀티턴 상태 관리 필요
알림·연동 Integration Agent	개정 요약 알림, 파일 전달, 외부 시스템 연계 판단	외부 어댑터 호출. 실패·재시도 처리 책임




그림 C. 에이전트 구성 — Router 위임, 에이전트별 전용 도구, 검증 분리 (점선 = 확장 구성)

기능 편입 단계

설계는 위 전체 구성을 목표로 하며, 적용 범위는 아래 단계로 확장합니다. 단계는 기능이 편입되는 범위의 구분이며, 실제 구현 진행 방식은 § 10의 노트를 따릅니다.

단계	구성	판단 근거
1단계	Router + 문서 탐색 + 문서 해석 + 검증 (4개)	검색·요약이 초기 범위의 대부분이며, 검증은 근거 신뢰를 위해 처음부터 분리 필요
2단계	+ 문서 작성 + 알림·연동	작성 지원과 CUBE 연동이 편입되는 시점에 추가
3단계	병렬 실행·에이전트 간 협업 확대	복합 질의(비교·다문서 종합) 수요가 확인되면 검토

설계 규칙

다중 구성이 비용·지연으로 이어지지 않도록 다음을 원칙으로 둡니다. 첫째, **기본 경로는 위임 1회로 종결합니다** — Router가 담당 에이전트 하나를 선택해 맡기고 그 결과로 응답하며, 여러 에이전트를 이어 부르는 것은 명시적으로 정의된 시나리오(예: 요약 후 비교)에 한정합니다. 둘째, **에이전트 간 호출 깊이는 2단계로 제한**하며 상호 재귀 호출을 금지합니다. 셋째, 각 에이전트는 **자신의 도구만** 호출할 수 있어 권한과 책임 경계가 코드로 강제됩니다. 넷째, Router는 경량 모델을 사용해 분류 지연을 억제하고, 규칙으로 판별 가능한 패턴(문서번호 직접 입력 등)은 모델 호출 없이 라우팅합니다. 다섯째, 에이전트별로 프롬프트·도구·모델을 독립 버전 관리해 **한 영역의 개선이 다른 영역에 영향을 주지 않도록** 합니다.

기대 효과와 대가 — 에이전트를 분리하면 프롬프트가 짧고 명확해져 각 영역의 정확도를 개별적으로 개선·측정할 수 있고, 평가 회귀도 에이전트 단위로 수행됩니다. 대가는 라우팅 오류라는 새로운 실패 유형이 생긴다는 점이며, 이를 위해 **분류 정확도를 평가 지표에 포함**하고 오분류 시 기본 경로로 안전하게 수렴하도록 설계합니다.

도메인 특화 서브 에이전트 — 고도화 검토 항목 — 현재 분담은 기능(역할) 단위이며, 문서 도메인(공정·품질·환경안전 등)의 차이는 에이전트를 늘리지 않고 데이터로 흡수합니다 — 메타 필터, 용어 사전(term_synonym), 문서 유형 프로파일, 그리고 판별된 도메인에 따라 지시문에 주입하는 **도메인 프로파일**(용어·해석 주의사항). 도메인별 에이전트 분리는 질의당 호출 비용은 거의 늘지 않지만 유지·평가 비용(에이전트별 프롬프트·평가 세트·회귀 매트릭스)이 도메인 수에 비례해 커지므로 초기에는 채택하지 않습니다. 고도화 단계에서 다음 두 조건이 확인되면 검토합니다 — ① 도메인별 평가에서 특정 도메인의 정확도가 지속 미달하고 프로파일 주입으로 해소되지 않음 ② 도메인 간 차이가 지식이 아니라 **도구·추론 절차의 차이**로 확인됨. 판단 근거 확보를 위해 평가 지표는 도메인 축으로 분해해 측정합니다.

4.3 실행 하네스와 가드레일

에이전트의 판단 규칙(§ 4.2)과 별개로, 모든 에이전트가 공통으로 올라타는 **실행 기반(하네스)**과 입출력 **경계 통제(가드레일)**를 둡니다. 반복 상한·전용 도구·권한 필터처럼 앞 절들에 개별 기술된 통제도 실제 구현은 이 계층에서 코드로 강제됩니다.

구분	항목	내용
실행 하네스 (공통 실행 기반)	도구 호출 검증	모든 도구의 입력·출력을 스키마로 검증. 불일치 시 1회 재시도 후 안전 응답으로 전환
	시간·횟수 상한	도구별 타임아웃, 에이전트별 도구 호출 횟수 상한, 요청 전체의 응답 데드라인 — 초과 시 그 시점까지의 결과로 응답 전환
	실행 추적	도구 호출·프롬프트·모델 응답을 세션 단위로 기록(message의 도구 실행 이력) — 오류 재현·품질 분석·감사의 원천
	오류 격리	개별 도구 실패가 세션 실패로 번지지 않도록 도구별 폴백 정의(검색 실패 시 축소 검색, 검증 실패 시 보수 응답)
가드레일 (경계 통제)	입력 경계	검색된 문서 내용은 지시가 아닌 데이터로 구분 태깅 해 문서 내 문구가 에이전트 지시로 해석되는 것(프롬프트 인젝션)을 차단. 표준문서와 무관한 범위 밖 질의는 안내 응답으로 전환
	권한 경계	인가 판정을 검색 결과 필터 지점에 배치(§ 9 ADR 9) — 권한 밖 문서는 답변 근거로도 사용되지 않음
	출력 경계	Verifier의 근거 일치 검증으로 무근거 답변 차단, 출처 인용 강제, 미달 시 "문서에 없음" 안전 응답(§ 3 7단계)
	행위 경계	에이전트별 도구 화이트리스트(자신의 도구만 호출 가능, § 4.2 설계 규칙) — 권한·책임 경계를 코드로 강제

5. Data Pipeline 처리 흐름

5.1 전체 처리 경로

원본 문서를 검색 가능한 자산으로 변환하는 경로입니다. 각 단계의 산출물을 저장해 **부분 재실행**이 가능하도록 설계합니다 — 예를 들어 임베딩 모델만 바뀌면 파싱 결과를 재사용하고 임베딩부터 다시 수행합니다.

단계	처리	산출물(저장)	비고
1	수집 (Ingest)	원본 파일 참조, 문서 식별자, 변경 해시, 문서 유형 태그 (사전 등록 프로파일 — § 5.2 ①)	변경 감지로 증분 처리. 해시 동일 시 이후 단계 건너뛸. 유형 태그는 문서번호 체계·메타·제목 규칙으로 자동 부여, 예외는 관리 화면 지정
2	형식별 파싱	구조 보존 Markdown (본문·섹션 계층 — 아래 노트), 첨부 목록, 이미지 위치·주변 텍스트 (캡션·전후 문단)	Excel·PDF·구 Office 형식별 처리기 분리. 실패 유형 기록. 문서 단위 이미지 비중 측정 → 이미지 중심 문서 분류
3	구조 인식	표(구조 보존 텍스트), 도식(Mermaid), 이미지 OCR 텍스트	원본 위치 좌표를 함께 저장해 출처 링크에 사용. 변환 실패 시 원본 링크 폴백으로 표시
4	메타·관계·요약 추출	문서번호·제목·Owner·부서·Site·레벨·개정 이력, 인용 관계, 문서 요약 (doc_summary)	메타는 정규화 규칙, 관계는 주어·술어·목적어 정규화, 요약은 LLM 생성(아래 노트) — 개정(Rev.) 단위로 재생성
5	정제·청킹	청크 텍스트, 섹션 경로, 부모-자식 관계	섹션 경계 우선 청킹. 장문은 분할하되 상위 맥락을 부모로 연결
6	임베딩·색인	벡터 + 메타데이터 페이로드 동봉 (문서번호·제목·Owner·부서·Site·레벨·Rev·상태·섹션 경로·자산 출처·신뢰도· 이미지 원본 위치 참조), 키워드 인덱스(기 구축 Elasticsearch의 청크 단위 전용 인덱스 — § 2.1 노트)	Model Gateway 경유. 배치 크기·재시도 정책 적용. 벡터와 메타를 한 레코드로 묶어 저장 — 검색 시 필터·정렬·권한 판정과 결과 표시가 조인 없이 처리됨
7	검증	처리 통계, 실패 목록, 샘플 품질 지표	실패·품질 미달 문서는 색인 제외 후 목록화

공통 중간 표현 — 구조 보존 Markdown — Word·PPT·PDF는 제목 계층·목록·표 등 일정한 양식을 갖고 있으므로, 형식별 파서의 산출물을 **Markdown 하나로 정규화**해 이후 단계가 단일 형식만 다루도록 합니다. 효과는 네 가지입니다. 첫째, 제목 계층이 텍스트에 남아 **섹션 경계 청킹이** 일관되게 적용됩니다. 둘째, LLM은 Markdown 구조 표기(제목·표·목록)를 학습 과정에서 충분히 접한 형식이므로, 평탄화된 텍스트보다 **문서의 양식과 위계를 더 정확히 이해**합니다 — 조항 위치 파악, 표 안 값 참조, 섹션 경로 인용의 정확도가 올라갑니다. 셋째, 챗봇 화면 표시(인용·표 렌더링)가 추가 변환 없이 처리됩니다. 넷째, Markdown 산출물이 저장되는 중간 산출물이므로 **부분 재실행**의 기준점이 됩니다. 유의점: 병합셀 등 복잡한 표는 파이프 표에서 손실되므로 HTML 표 블록으로 병존 저장하고, PPT는 슬라이드를 섹션 단위로 선형화(제목 → 본문 → 발표자 노트)하며, 읽기 순서가 모호한 PDF 레이아웃은 순서 검증 대상으로 표시합니다.

문서 요약 자산(doc_summary)의 생성과 활용 — 4단계에서 파싱된 Markdown을 입력으로 문서별 요약(전체 요약·목적·적용 범위·주요 규정)을 LLM으로 생성해 별도 자산으로 저장합니다. 활용처는 네 곳입니다. ① **유사 문서 검색**: 문서 간 유사도 산출을 본문 전문 임베딩이 아니라 **요약·핵심 임베딩 기준**으로 수행합니다 (§ 9 ADR 6) — 장문 표준문서는 서식·공통 문구 비중이 커 전문 임베딩으로는 형식이 비슷한 문서가 상위에 오르기 때문입니다. ② **검색 결과 표시**: 결과 목록의 문서 카드에 요약을 노출해 열람 전 판단을 돕습니다. ③ **개정 알림**: 문서 개정 시 관련자에게 전달되는 요약 알림의 본문 소스가 됩니다. ④ **문서 해석 에이전트의 사전 맥락**: 지정 문서 요약 요청 시 저장된 요약을 캐시로 활용해 응답 시간과 토큰을 절감하고, 장문 해석 시 시작 맥락으로 제공합니다. 요약은 개정 단위로 재생성하며 생성 모델·버전을 함께 저장해 모델 교체 시 선별 재생성이 가능합니다.




그림 D. Data Pipeline 7단계와 저장소 접점 — 단계별 산출물 저장으로 부분 재실행 지원

5.2 이미지·도식 처리 서브파이프라인 (OCR + VLM 복합)

실제 표준문서에서 확인된 이미지 유형은 성격이 크게 다릅니다 — 응용프로그램 사용 절차를 설명하는 **화면 캡처(강조 박스·번호 주석 포함)**, **이미지로 저장된 표, 플로우차트 등 워크플로 도식**, 스캔 텍스트 등이 혼재합니다. 특히 화면 캡처의 강조 표시(빨간 박스)와 번호 주석은 문자가 아니라 **공간적 지시 관계**(어느 영역을 가리키며 몇 번째 절차인지)라서 OCR만으로는 의미가 소실됩니다. 따라서 **이미지 분석(분류) 결과에 따라 유형별로 적합한 처리 경로를 타는 라우팅 구조**를 설계의 중심에 두고, 저비용 처리를 1차로 하되 유형·신뢰도에 따라 상위 모델로 승격하는 계층 구성을 결합합니다.

유형 판별의 구현 — 문서 컨텍스트 우선, OCR 단독으로는 분류가 어렵습니다

OCR은 문자와 좌표만 산출하므로 화면 캡처의 UI 요소·강조 박스, 도식의 화살표, 차트의 형상 같은 비문자 시각 특징을 보지 못해 유형을 확정할 수 없습니다. 한편 샘플 문서 기준으로 장식·로그성 이미지의 비중이 낮아, 픽셀 특징(크기·색상) 기반 사전 필터의 실익도 제한적입니다. 따라서 판별은 **문서 컨텍스트를 주 신호**로 구성합니다.

① **문서 유형 사전 등록(처리 프로파일)**: 파이프라인이 모든 것을 스스로 추론하게 두지 않고, 대표 문서 유형 몇 가지(예: 절차서·지침서·시스템 사용 매뉴얼·양식·스캔 문서)를 **처리 프로파일로 미리 등록**합니다. 프로파일에는 해당 유형에서 예상되는 이미지 구성(화면 캡처 다수·표 위주 등), 캡션 표기 관행, 표 비중, 청킹 정책이 담기고, 수집 단계에서 문서번호 체계·메타데이터·제목 규칙으로 각 문서에 유형 태그를 부여합니다(자동 부여가 어려운 문서는 관리 화면에서 지정). 이후 ①~③의 판별은 이 프로파일을 사전 정보로 활용해 정확도가 올라가고 VLM 보완 호출이 줄어들며, 유형별 청킹·색인 정책 차등의 기준도 됩니다. 8/10 샘플 확인 결과가 프로파일 초기값의 근거가 됩니다.

① **문서 컨텍스트 기반 추정(주 경로, 무비용)**: 파서가 보존한 이미지 주변 신호로 유형을 추정합니다 — 캡션·라벨 패턴("표 N", "그림 N", "○○ 화면", "절차"), 직전 문단의 서술("다음 화면에서 …를 클릭"), 섹션 제목, 문서 내 위치와 이미지 순서. 표준문서는 서술 관행이 일정하므로 상당수가 이 단계의 패턴 규칙으로 판별될 것으로 예상하며, 규칙으로 애매한 경우 주변 텍스트만으로 텍스트 LLM에 판별시키는 저비용 보조를 둘 수 있습니다(이미지 입력 불필요). 극소형 아이콘 제거 같은 크기 필터는 보조 수단으로만 유지합니다.

② **VLM 저비용 호출 분류(보완 경로)**: 컨텍스트 신호가 없거나 서로 상충할 때만 이미지를 직접 봅니다. 가용 VLM(Kimi-2.6·Qwen 3.8)에 저해상도 축소본을 입력하고 유형 한 단어만 출력하게 해 본 판독 대비 호출 비용을 낮추며, 확보된 컨텍스트 신호를 프롬프트에 함께 제공합니다. 소형 VLM 추가 확보 시 이 단계 전용으로 배정하는 최적화 옵션, 라벨 데이터 축적 후 자체 분류기 학습은 대체 검토 사항입니다.

③ **보수적 라우팅**: 추정이 모호하면 상위 경로(VLM 판독)로 보냅니다 — 오분류의 비용이 비대칭이기 때문입니다(VLM 경로로 잘못 가면 비용만 늘지만, OCR 경로로 잘못 가면 정보가 소실됩니다). 컨텍스트 추정의 정확도는 평가 대상이며(§ 5.6), 유형별 오분류가 확인되면 패턴 규칙을 보강합니다.

④ **이미지 위주 문서의 별도 경로**: 본문 텍스트가 거의 없이 이미지 연속으로 구성된 문서는 컨텍스트 신호 자체가 없으므로 ①이 성립하지 않습니다. 문서 단위 이미지 비중 측정으로 **"이미지 중심 문서"로 분류**하고, 개별 이미지 처리 대신 **문서 전체를 순서 있는 시퀀스로 VLM에 해석**시켜 페이지 간 절차 연속성을 보존합니다. 처리 비용이 높으므로 해당 문서 목록을 별도 관리하고 배치 예산을 우선 배분합니다.

자산 유형	1차 처리	승격 처리(조건부)	산출물
화면 캡처 +주석 절차	VLM 1차 — 이미지와 OCR 문자를 함께 입력해 강조 영역·번호 순서·대상 UI 요소를 해석	두 VLM 교차 검증(중요 문서 한정)	단계별 절차 텍스트(순번·대상 화면 요소·설명) — OCR-first 경로의 예외 유형

스캔 텍스트	OCR 전용 모델 — 문자·좌표 추출	저신뢰 영역만 VLM 재판독	본문 텍스트 + 위치 정보
표(이미지)	OCR로 셀 그리드·문자 추출	VLM으로 병합셀·다단 헤더 정규화	구조 보존 표(Markdown/HTML)
도식·순서도	OCR로 라벨 텍스트 추출	VLM에 이미지 + OCR 라벨을 함께 입력해 구조 해석	Mermaid + 단계 서술 텍스트
그래프·차트	OCR로 축·범례 추출	VLM으로 추세·비교 서술 생성	서술 텍스트(수치 표 병기)
수식·기호	OCR 수식 모드	VLM 보정	텍스트 또는 수식 표기
사진·로고·장식	캡션만 수집	—	색인 제외(캡션만 보관)

핵심 설계 — OCR 결과를 VLM의 근거로 제공

VLM에 이미지만 주고 텍스트를 생성하게 하면 라벨을 그럴듯하게 지어내는 문제가 발생합니다. 반면 OCR이 추출한 문자열과 좌표를 함께 입력하고 **"주어진 라벨만 사용해 구조를 구성하라"**는 제약을 걸면, 문자 판독은 OCR의 강점(정확도·저비용)이, 구조·의미 해석은 VLM의 강점이 각각 발휘되고 환각이 크게 줄어듭니다. 도식 변환에서 이 조합이 단일 모델 대비 가장 실효가 큼니다.




그림 E. 이미지 처리 스마트 라우팅 — 유형 판별이 경로를 결정, 전 경로가 품질 게이트로 수렴

5.3 모델 구성과 라우팅 정책

역할	후보(확인된 가용 자원)	배정 근거·운영 방식
OCR 전용	사내 OCR 솔루션 / 오픈소스 OCR (확인 진행 중)	문자 정확도와 좌표 추출, 대량 배치에 유리하고 호출 비용이 낮음. 전 이미지에 1차 적용
문서 이해 VLM	Kimi-2.6 VLM	문서 레이아웃·표·도식 이해에 강점. 표 정규화와 도식 구조 해석의 주 모델로 배정
범용 VLM	Qwen 3.8	다국어·범용 이미지 서술. 차트 서술, 교차 검증(세컨드 오피니언) 용도
판정·검증	텍스트 LLM	변환 결과의 자기 정합성 검사(라벨 누락·순서 모순 탐지)

라우팅 정책 — ① 유형이 경로를 우선 결정합니다: 화면 캡처·도식처럼 공간 관계 해석이 본질인 유형은 처음부터 VLM 경로를 타며, OCR-first 원칙은 문자 판독이 본질인 유형에만 적용합니다. ① 유형·신뢰도 기반 승격: 1차 산출물이 임계를 넘으면 상위 모델을 호출하지 않습니다. ② 우선순위: 표·도식 > 스캔 텍스트 > 차트 > 장식 순으로 VLM 예산을 배분합니다. ③ 비용 상한: 배치별 VLM 호출 비용 상한을 설정하고 초과분은 다음 주기로 이월합니다. ④ 교차 검증: 중요도가 높은 자산에 한해 두 VLM의 결과를 비교하고 불일치 시 폴백 처리합니다. ⑤ 모델 지정은 설정으로 관리하며 Vision Gateway가 실제 호출을 담당해 모델 교체가 코드 변경 없이 가능하도록 합니다.

5.4 품질 게이트와 폴백

유형	판정 지표	미달 시 처리
화면 캡처 절차	절차 번호의 연속성, 강조 영역·설명 대응 여부, OCR 문자와 산출 텍스트의 정합	교차 검증 불일치 시 원본 이미지 링크 + 추출 문자만 색인
스캔 텍스트	평균 문자 신뢰도, 미인식 비율, 언어 판별 일치	해당 영역만 VLM 재판독 → 그래도 미달 시 색인 제외 + 원본 링크
표	행·열 수 일관성, 셀 결손율, 헤더 인식 여부	VLM 정규화 재시도 → 실패 시 원본 이미지 링크로 폴백
도식	Mermaid 구문 파싱 성공 여부 , 노드·엣지 수와 OCR 라벨 수의 정합, 고립 노드 비율	재생성 1회 → 실패 시 라벨 나열 텍스트만 색인하고 원본 링크 제공
차트	축·범례 추출 여부, 수치 언급의 근거 존재	서술 생략, 캡션만 색인

모든 자산은 **변환 신뢰도와 처리 계층(tier)**, **사용 모델·버전**을 함께 저장합니다. 이는 세 가지 목적을 갖습니다 — 검색 시 신뢰도가 낮은 텍스트에 가중치를 낮게 주고, 화면 표시에서 "재구성" 여부를 안내하며, 모델 교체 시 해당 계층의 자산만 선별 재처리합니다.

5.5 임베딩·색인 반영 정책

이미지에서 파생된 텍스트는 본문 텍스트와 **동일한 가중치로 색인하지 않습니다**. 판독 오류가 검색 품질을 떨어뜨릴 수 있으므로 별도 필드로 구분해 색인하고, 검색 결과에는 이미지 출처임을 표기합니다. 도식의 Mermaid 산출물은 그 자체가 읽히는 텍스트이므로 색인 대상이며, 노드 라벨과 연결 관계가 검색어와 매칭됩니다. 표는 구조 보존 텍스트를 색인하되 셀 단위가 아닌 행 단위로 묶어 맥락을 유지합니다.

5.6 모델 선정 검증 계획

모델 조합은 공개 벤치마크가 아니라 **실제 표준문서 샘플**로 결정합니다. 8/10 사전 확인 시 확보되는 샘플에서 유형별 대표 이미지를 추출해 기준셋을 만들고, 후보 조합을 동일 기준으로 비교합니다.

측정 항목	지표	비교 대상
유형 판별	분류 정확도(유형별 혼동 행렬), 컨텍스트 추정 단독 정확도·커버리지	컨텍스트 추정 vs 컨텍스트+VLM 보완 vs 전수 VLM 분류, 문서 유형 프로파일 적용 전후
화면 캡처 절차	절차 단계 재현율(순번·대상·설명 일치), 강조 영역 해석 정확도	VLM 단독 vs OCR 문자 동봉, Kimi-2.6 vs Qwen 3.8
문자 판독	문자 정확도, 한글·영문 혼재 구간 오류율	OCR 단독 vs OCR+VLM 보정

표 구조	셀 정합률, 병합셀 처리 성공률	OCR 단독 vs VLM 정규화
도식 해석	노드·엣지 정확도, Mermaid 파싱 성공률	VLM 단독 vs OCR 라벨 제공 조합, 모델별 비교
이미지 중심 문서	문서 단위 절차 재현율, 페이지 간 순서 보존	개별 이미지 처리 vs 시퀀스 일괄 해석
처리량·비용	페이지당 처리 시간, VLM 호출 비율	계층 라우팅 적용 전후

도식·표 처리 원칙 — 구조 인식 결과는 원본을 대체하지 않고 **원본과 병존**합니다. 검색은 변환 텍스트를 대상으로 하고, 화면 표시는 변환 결과를 렌더링하되 "재구성" 표기와 원본 위치 링크를 함께 제공합니다. 변환 신뢰도가 낮은 유형(복잡 도식·병합셀 다단 표)은 초기부터 폴백 대상으로 분류합니다.

5.7 파이프라인 가동 모니터링

초기 전량 색인은 장시간 배치이고 상시 정제는 무인 운영이므로, **지금 어느 단계에서 무엇을 처리 중인지**가 화면에서 확인되어야 합니다. 각 문서는 처리 단계(①수집~⑦검증)를 상태 머신으로 통과하며, 단계 전환마다 이벤트를 기록해 아래 화면과 지표를 구성합니다.

모니터링 뷰	표시 내용	용도
실행(Run) 현황	배치 실행별 — 전체 대상 건수, 단계별 처리 중/완료/실패 건수, 진행률(정량 Progress Bar), 시작 시각·예상 잔여 시간(최근 처리 속도 기반)	전량 색인·재색인의 진행 파악, 완료 시점 예측
단계별 큐 현황	①~⑦ 각 단계의 대기·처리 중 건수, 단계별 평균 처리 시간, 병목 단계 표시	병목 식별(예: OCR·VLM 단계 적체) → 워커 증설 판단
문서 단위 상세	개별 문서의 현재 단계·소요 시간·처리 이력(단계별 타임스탬프), 문서번호로 검색	"이 문서가 왜 아직 검색이 안 되는가" 추적
실패·폴백 목록	실패 문서(단계·실패 유형·오류 메시지), 품질 게이트 미달로 폴백된 자산 목록, 재시도 버튼	실패 유형 집계 → 파서·모델 개선 근거, 선별 재처리
모델 호출 현황	OCR·VLM·임베딩 호출 수/실패율/평균 지연, VLM 승격 비율, 쿼터 소진율	비용 통제, 라우팅 정책(승격 임계) 조정 근거

병렬 처리 전제 — 파이프라인은 문서 단위로 독립적이므로 **기본이 병렬 실행**입니다. 큐 기반으로 워커 여러 개가 동시에 문서를 처리하며, 단계별 특성에 맞춰 동시성을 달리 둡니다: 파싱은 CPU 워커 수만큼, OCR·VLM 단계는 모델 호출 한도(쿼터·GPU)에 맞춘 동시 호출 상한으로, 임베딩은 배치 묶음 단위로 처리합니다. 이 전제에서 모니터링이 갖춰야 할 것은 다음과 같습니다.

병렬 관련 요건	내용
워커 현황	워커별 현재 처리 중 문서·단계·경과 시간 표시. 유휴/가동 워커 수로 증설·축소 판단
진행률 집계	문서들이 서로 다른 단계에 동시에 있으므로 진행률은 단계 통과 수 합산이 아니라 문서 단위 완료 기준 으로 집계(완료 문서 수 / 전체). 단계별 분포는 큐 현황 뷰가 담당
순서 보장	같은 문서의 개정판이 연속 등록되면 병렬 워커가 순서를 뒤바꿀 수 있으므로 문서 단위 직렬화 (동일 문서번호는 동일 파티션/락) 적용
중복 방지·재개	작업 선점(claim) 시각 기록으로 이중 처리 방지, 워커 중단 시 타임아웃 후 자동 재큐잉. pipeline_task의 상태 전이가 그 근거
실패 격리	한 문서의 실패가 배치 전체를 중단시키지 않음 — 실패 건은 목록으로 분리하고 나머지는 계속 진행
공유 자원 역압	VLM·임베딩 호출이 쿼터 한도에 근접하면 해당 단계 워커만 대기시키는 단계별 역압(backpressure) — 병목 표시와 연동

구현 방식 — 별도 시스템을 도입하기보다 파이프라인이 이미 기록하는 데이터를 활용합니다. 문서별 처리 상태 테이블(pipeline_run · pipeline_task — 속성은 § 6.2 참조)을 § 6 저장 구조에 추가하고, 조회 화면은 Admin API에 엔드포인트

트(/admin/pipeline/runs, /admin/pipeline/tasks)를 엮어 관리 화면에서 표시합니다. 알림은 두 조건에서 발생시킵니다 — 실행 완료·중단 시, 그리고 실패율이나 특정 단계 적체가 임계를 넘을 때. 운영 체계(§ 2.1 Observability)와 지표를 공유하되, 이 화면은 개발·운영 담당자용이며 일반 사용자에게는 노출하지 않습니다.

5.8 신규·개정 문서 반영 워크플로

초기 전량 색인 이후 운영 중에는 문서 추가·개정·폐기가 상시 발생합니다. 초기 범위에서는 § 2.2의 주기 배치(변경 해시 비교)로 반영하고, 아래 워크플로의 자동화 수준(이벤트 기반 즉시 반영·알림 연동)은 **고도화 단계에서 확장**합니다.

단계	처리	내용	비고
1	감지	등록·개정 이벤트 수신 또는 주기 스캔, 변경 해시 비교	초기는 주기 스캔, 이벤트 연동은 고도화
2	판정	신규 / 개정 / 폐기 구분. 개정은 Rev 비교로 변경 범위 식별	document·revision 테이블 기준
3	처리	신규: 전체 파이프라인(①~⑦) 통과 / 개정: 재파싱 후 신규 Rev로 색인하고 구 Rev 청크·벡터는 상태 전환(기본 검색 제외, 이력 조회 유지) / 폐기: 색인 제외 + 상태 갱신	신규 Rev 색인 완료 후 전환해 검색 공백 방지
4	파생 자산 갱신	문서 요약(doc_summary) 재생성, 관계(doc_relation)·개정 계보 갱신	§ 5.1 4단계 재실행
5	알림	개정 요약 알림 발송 — 요약 자산을 본문으로 활용	알림 연동 편입 시점부터(고도화)
6	확인	색인 반영 검증, 증분 실행으로 모니터링(§ 5.7)에 기록	pipeline_run 유형 = 증분

6. 데이터 저장 구조 초안

저장소 제품이 미확정이므로 논리 모델로 기술합니다. 관계형 + 벡터 인덱스 조합을 기본 가정으로 하되, 사내 허용 제품 확인 후 매핑합니다.

6.1 문서·검색 도메인

엔티티	주요 속성	용도
document	문서번호(정규화 키), 제목, 레벨, Owner(사번), 부서, Site, 현재 Rev, 상태(유효/개정중/폐기), 유효성 평가 기한, 원본 위치	검색 결과 기본 메타 출력(행 18), 필터 검색의 축
document_revision	문서ID, Rev, 개정일, 개정 사유, 변경 요약, 원본 스냅샷 참조	Rev. 비교(행 19), 개정 알림(행 51)
chunk	문서ID, Rev, 섹션 경로, 순번, 본문, 부모 청크, 토큰 수	검색 단위. 부모-자식으로 맥락 확장
chunk_vector	청크ID, 임베딩 벡터, 임베딩 모델 버전, 메타 페이로드 (문서번호·레벨·Owner·부서·Site·Rev·상태·섹션 경로·자산 유형/신뢰도· 이미지 원본 위치 참조)	의미 검색 + 벡터 저장소 내 필터·정렬. 이미지 파생 청크는 원본 위치 참조(doc_asset) 가 특히 중요 — 검색 결과에서 원본 이미지를 즉시 표시해야 하는 경우가 있어, 조회 없이 원본으로 연결되는 키를 페이로드에 포함. 관례대로 벡터와 메타를 동일 레코드로 저장해 검색 단계에서 관계형 조인 없이 필터링. 정본(source of truth)은 document 테이블이며 페이로드는 사본 — 메타 변경 시 동기화 갱신 필요. 모델 버전 기록으로 재색인 범위 판단
doc_asset	문서ID, 유형(표/도식/이미지), 원본 위치, 변환 포맷(Mermaid/구조 텍스트), 변환 신뢰도, 폴백 여부	도식·표 재현(§ 5), 검색 대상 텍스트 제공
doc_relation	주체 문서ID, 관계유형(인용/상위/대체/후속), 대상 문서ID, 근거 위치	연관 문서(행 25), 번호·레벨 변경 추적(행 24). 주어-술어-목적어 정규화
doc_summary	문서ID, Rev, 요약문, 핵심 항목(목적·적용범위·주요 규정), 생성 모델·시각	지정 문서 요약 캐시 + 유사 문서 산출의 기준 자산 (행 32·39)
term_synonym	표준어, 유사어·약어 목록, 적용 범위	유사어 검색 확장(행 16)




그림 F. 데이터 모델 개요 — 문서 도메인(청색)과 대화·운영 도메인(주황·회색)

6.2 대화·운영 도메인

엔티티	주요 속성	용도
session	사용자ID, 시작·최종활동 시각, 상태, 만료 시각	맥락 유지(행 65), 타임아웃 집계(행 7)
message	세션ID, 역할(사용자/에이전트), 본문, 근거 참조 목록, 도구 실행 이력, 토큰 사용량	이력 조회·키워드 검색(행 67), 재생성(행 66)
memory_note	사용자ID, 유형(교정/선택), 내용, 출처 메시지, 유효 기간	해석 확정 시 세션 초과 메모리(행 65-b). MVP는 명시적 고정만 최소 저장
feedback	메시지ID, 유형(명시/암묵), 값, 사유, 수집 시각	피드백 수집(행 4), 개선 근거

audit_log	사용자ID, 행위(검색/요약/다운로드), 대상 문서, 시각, 결과	감사 추적(행 69)
generated_doc	생성 문서ID, 요청자, 생성 시각, 사용 모델·버전, 근거 문서 목록, 검토 상태	AI 생성문서 추적 메타데이터(행 70)
pipeline_run / pipeline_task	실행ID, 유형(전량/증분/재색인), 대상 건수 / 문서ID, 단계, 상태(대기·처리중·완료·실패·폴백), 워커ID, 선점(claim) 시각, 시작·종료 시각, 재시도 횟수, 오류 유형	파이프라인 가동 모니터링(§ 5.7) — 진행률·병목·실패 추적의 원천
eval_set / eval_run	질문, 정답 문서, 정답 요지 / 실행 시각, 지표값, 모델·프롬프트 버전	정확도 회귀 측정(§ 7.5 평가 체계)
model_registry	내부 모델명, GiaA 표준 모델명, 용도(생성/임베딩/판정), 버전, 활성 여부	모델 버전 관리(행 3), 교체·롤백

7. 인터페이스 초안

7.1 내부 인터페이스 (UI ↔ 서비스)

엔드포인트(안)	방식	요청 → 응답
/chat/query	POST (스트리밍)	{세션ID, 질의, 옵션} → 상태 이벤트 + 토큰 스트림 + 최종 결과(답변, 근거 목록, 첨부 자산)
/chat/regenerate	POST	{메시지ID, 지시(더 짧게/표로)} → 재생성 응답
/sessions	GET/POST/DELETE	세션 목록·생성·종료
/sessions/{id}/messages	GET	대화 이력 조회(키워드 필터 지원)
/documents/{docNo}	GET	문서 메타·요약·자산 조회
/documents/{docNo}/revisions	GET	개정 목록 및 변경점 비교
/files	POST/GET	업로드(검증 포함)·다운로드 URL 발급
/feedback	POST	명시적 피드백 등록
/admin/reindex	POST	재색인 트리거(범위 지정)
/admin/pipeline/runs	GET	배치 실행 현황 — 단계별 건수·진행률·예상 잔여 시간
/admin/pipeline/tasks	GET	문서 단위 처리 상태 조회(문서번호 검색, 실패·폴백 필터)
/admin/models	GET/PUT	모델 매핑 조회·활성 버전 전환

7.2 외부 인터페이스

대상	방향·용도	설계 시 고려
GiaA	호출 — 생성·임베딩·판정	Model Gateway가 유일한 접점. OpenAI 호환 여부에 따라 어댑터 구현이 달라짐(확인 필요). 쿼터 초과 시 큐잉·백오프, 실패 시 사용자 안내 문구 규격화
G-HeSS DB	조회 — 표준문서 원본·메타	접근 방식(API/DB 직접/파일 추출)에 따라 Ingestor 구현이 같음. 증분 감지 수단(변경 시각·해시) 확보 필요
CUBE / CUBE BOT	송신 — 알림 / 수신 — 검색 요청	알림 방식(알림센터 연계 vs 메시지 POST) 미확정 → Notification Adapter 인터페이스만 고정. CUBE 측 응답 형식이 상이할 수 있어 표현 계층 분리 필요
전자결재	송수신 — 결재 진행·상태	확장 범위(§ 10 WP-18). 상태 조회는 폴링/웹훅 중 가용 방식 확인
HR	조회 — 조직·Owner 정보	동기화 주기·기준(CCG 코드) 확인. 개인정보 이용 승인 선행
SSO	인증	사용자 식별자와 부서·직무 클레임 확보 범위 확인. 권한 판정의 입력

8. 배포·운영 토폴로지

컨테이너·오케스트레이션 가용 여부와 DevOps 지원 범위가 확정되지 않았으므로, 아래는 컨테이너 기반을 가정한 초안입니다.

실행 단위	확장 방식	비고
Web / API 서버	수평 확장	세션 상태를 외부 저장소에 두어 무상태 유지. 동시접속 목표에 따라 인스턴스 수 산정
Agent Worker	수평 확장	LLM 호출 대기가 길어 API 서버와 분리. 동시 호출 상한을 쿼터에 맞춰 제어
Pipeline Worker	배치 확장	파싱·OCR은 CPU/GPU 소모가 커 별도 노드 권장. 초기 전량 색인 시 일시 증설
Scheduler	단일	배치 트리거, 중복 실행 방지 락
Datastore	사내 표준 따름	관계형 DB + 벡터 인덱스. 제품은 허용 범위 확인 후 결정
Object Storage	용량 기반	원본·중간 산출물·생성 파일 보관

8.1 환경 구성

개발·검증·운영 3개 환경을 기본으로 하되, 자원 제약 시 개발·검증 통합을 검토합니다. 평가 회귀 측정은 검증 환경에서 정기 실행합니다.

9. 아키텍처 결정 기록 (ADR 요약)

ADR(Architecture Decision Record)은 어떤 결정을 왜 내렸고 어떤 대안을 검토했는지를 남기는 기록 형식입니다. 초안 단계에서 이미 방향을 정한 항목과 그 근거이며, 변경 시 이 표를 갱신해 결정의 이력을 남깁니다.

#	결정	근거	검토한 대안
1	Model Gateway를 통한 LLM 추상화	GiaA 스펙·모델이 통제 바이며 변경 가능성이 있음	직접 호출 — 교체 시 전면 수정 필요로 배제
2	하이브리드 검색(키워드+벡터) + 재랭킹	문서번호·약어는 정확 일치가, 자연어 질의는 의미 검색이 유리	벡터 단독 — 정확 일치 취약. 키워드 단독 — 자연어 질의 취약
3	제어된 에이전틱(고정 도구·반복 상한)	응답 시간·쿼터·회귀 검증 가능성 확보	완전 자율 ReAct — 비결정성으로 검증 곤란
4	도식·표를 구조화 텍스트로 변환 후 원본 병존	검색 대상화와 화면 재현을 동시에 충족, 원본 노출의 권한 문제 회피	원본 이미지 노출 — 검색 불가·권한 이슈. 텍스트 서술만 — 가독성 저하
5	관계 메타데이터를 파이프라인에 내장	연관 문서·개정 추적 요구를 충족하며, 후행 추가 시 전량 재파싱 필요	후속 단계 추가 — 재작업 비용 큼
6	유사도 산출을 요약·핵심 기준으로	장문 표준문서는 서식·공통 문구 비중이 커 전문 임베딩이 형식 유사도를 반영	전문 임베딩 — 형식 유사 문서가 상위 노출
7	UI는 단독 페이지 우선, 위젯화는 후속 확장	MVP 적용 범위가 G-HeSS 단독이며 위젯화 난제를 일정에서 분리	초기 위젯화 — CSP·격리·인증 이슈로 일정 부담
8	부분 재실행 가능한 파이프라인	모델·정책 변경 시 전량 재처리 비용 절감	일괄 처리 — 변경 시마다 전량 재실행
9	권한 판정을 검색 결과 필터 지점에 배치	생성 이후 필터링은 근거 누락·불일치 유발	응답 단계 필터 — 근거와 답변 불일치 위험
10	이미지 처리에 OCR·VLM 계층적 복합 구성	이미지 유형별로 요구 능력이 달라 단일 모델은 품질·비용 모두 불리. 저비용 1차 처리 후 조건부 승격으로 VLM 호출량 통제	VLM 일괄 처리 — 비용·시간 과다. OCR 단독 — 도식·표 구조 해석 불가
11	VLM 입력에 OCR 판독 결과를 근거로 동봉	라벨을 지어내는 문제를 억제하고 문자 정확도는 OCR, 구조 해석은 VLM이 담당하도록 역할 분리	VLM 단독 판독 — 라벨 환각 위험
12	이미지 파생 텍스트를 본문과 분리 색인	판독 오류가 본문과 동일 가중치로 검색에 영향을 주지 않도록 하고, 출처 표기를 가능하게 함	동일 색인 — 오류 전파. 색인 제외 — 도식 내 정보 검색 불가
13	파싱 산출물을 구조 보존 Markdown으로 정규화	제목 계층·표·목록이 텍스트에 보존되어 청킹 일관성과 LLM의 양식 이해도가 함께 향상되고, 이후 단계가 단일 형식만 처리	평문 추출 — 구조 소실로 청킹·해석 품질 저하. 형식별 개별 표현 유지 — 후속 로직 중복
14	문서 유형 처리 프로파일 사전 등록	대표 유형의 처리 특성을 미리 알려 판별 정확도를 높이고 VLM 보안 호출을 절감, 유형별 청킹 정책 차등의 기준 확보	전면 자동 추론 — 판별 비용·오류 증가

10. WBS 연계 — 모듈·작업 패키지 매핑

본 장은 아키텍처 모듈을 WBS의 작업 패키지(Work Package) 후보로 변환한 것입니다. 각 행이 WBS의 1개 항목이 되도록 산출물과 선행 의존을 명시했으며, 담당 구분은 역할 분담(선행 문서 § 10) 기준입니다. 공수 산정은 W0~W1 확인 결과를 반영해 별도로 수행합니다.

WP	작업 패키지	산출물	선행 의존	담당	단계
WP-01	아키텍처 상세 설계	본 문서 확정판, I/F 정의 초안	스택·인프라 확인(W0~W1)	리드	W1
WP-02	Model Gateway	GiaA 어댑터, 모델 레지스트리, 쿼터 제어	GiaA API 규격 확인	리드	W1~2
WP-03	Ingestor + 형식별 Parser	수집·변경 감지, Excel/PDF/구 Office 처리기	표준문서 접근 방식 확인	A	W2~3
WP-04	Asset Classifier + Vision Gateway	문서 유형 프로파일 등록, 유형 판별(프로파일+컨텍스트 우선+VLM 보완), OCR·VLM 호출 계층	OCR 모델 확정, 샘플 기준셋	A	W2~3
WP-05	Structure Extractor (유형별 판독)	기본: 화면 캡처 절차·표 처리기, 품질 게이트 / 확장: 도식(Mermaid)·차트·수식, 두 VLM 교차 검증	WP-04	A	W3~4 (확장은 이월 가능)
WP-06	메타·관계·요약 추출 + 정규화 규칙	기본: 문서 메타 추출기, 문서 요약 생성(doc_summary), 정규화 규칙, 인용 관계 적재 / 확장: 개정 계보·상하위 관계	문서번호 체계 사전 질의 회신	A	W3 (확장은 이월 가능)
WP-07	청킹·임베딩·색인	청킹 정책, 색인 스키마, 전량 색인 배치	WP-02·03, 벡터 저장소 확정	A	W3~4
WP-08	Retrieval 계층	하이브리드 검색(키워드 축: 기 구축 Elasticsearch 연동), 재랭킹, 권한 필터 연동	WP-07, ES 인덱스 정책·접근 확인	리드	W3~4
WP-09	Agent Core — Router·탐색·해석	의도 분류, 문서 탐색·해석 에이전트, 도구 6종 연결	WP-02·08	리드	W3~5
WP-10	Verifier (근거 검증)	근거 일치 판정, 재생성·전환 로직	WP-09	리드	W4~5
WP-11	Chat UI + 처리 상태 피드백	단독 페이지 챗봇, 상태 이벤트 표시, 파일 업/다운로드	기존 디자인 시스템 확인, Chat API	B	W2~5
WP-12	세션·히스토리·재생성·기본 대시보드	세션 관리, 이력 검색, 재생성 명령, 기본 지표 화면	WP-11	B	W4~5
WP-13	공통 계층 — 인증·감사·관측	SSO 연동, 감사 로그, 지표 수집	SSO 규격 확인	B	W3~6
WP-14	평가 하네스	평가셋 관리, 검색·생성·분류 회귀 측정, 리포트	평가셋 수집(W2~3)	리드	W3~4
WP-15	배치·운영·파이프라인 모니터링	신규 문서 상시 정제, 타임아웃 집계, 재색인 도구, 가동 모니터링 화면(§5.7) — 기본: 실행 현황·실패 목록 뷰 / 확장: 단계 큐·문서 상세·모델 호출 뷰	WP-03~07	A	W6~7
WP-16	통합·안정화	E2E 연결, 성능 점검, 결함 수정	WP-08~13	전원	W6~9
WP-17	문서 작성 Agent + Checklist 검증	초안 생성, 대화형 수집, 검증 룰	DCC Checklist 확보	리드+B	후속
WP-18	알림·연동 Agent + CUBE 어댑터	알림 전송, 파일 전달, 외부 I/F 구현체	I/F 정의서 확정	리드+A	후속
WP-19	챗봇 위젯화	script 삽입형 위젯, 테마 오버라이드	WP-11, 적용 플랫폼 확인	B	후속

세분화 지침 — WBS 작성 시 각 WP를 산출물 단위로 1~4주 크기의 활동으로 쪼개고, 본 문서의 해당 절(\$ 표기)을 작업 내용의 근거로 연결합니다. 의존 관계는 위 표의 선행 의존 열을 그대로 선행 활동으로 옮기면 됩니다.

WBS 항목과 실제 구현 방식 — 위 WP는 범위와 산출물을 관리하는 단위이며, 모듈을 순서대로 하나씩 완성하는 진행 방식을 뜻하지 않습니다. 실제 구현은 짧은 반복 주기로 여러 모듈을 얹게 관통하는 동작 흐름(예: 소량 문서 색인 → 검색 → 답변 확인)을 먼저 구성한 뒤 각 모듈을 점진적으로 채워 가는 방식이어서, 하나의 WP가 여러 반복 주기에 걸쳐 부분적으로 진행될 수 있습니다. 진척 판정은 두 수준으로 구분합니다 — **실제 개발 진척은 반복 주기마다 나오는 동작하는 중간 산출물로 확인**하고, WBS 상의 진척 집계는 각 WP에 명시된 산출물의 완성 기준으로 환산해 표기합니다. 중간 산출물 확인 없이 WP 완성만 기다리면 문제 발견이 늦어지고, 반대로 중간 산출물을 그대로 WP 완료로 집계하면 완성도가 과대 표기되므로 두 수준을 함께 운용합니다.